

Relazione finale progetto

Caterina Ghiani

September 2026

Contents

1	Introduzione	1
2	Dataset	2
3	Metodologia	3
4	Risultati	4
5	Discussione	5
6	Conclusione	6

1 Introduzione

devo definire il problema e contestualizzarlo per chi legge:

- obiettivo di ricerca: qual è la domanda principale a cui il progetto vuole rispondere?
- contesto e motivazione: perché questo problema è importante o rilevante?
- scopo del report: cosa verrà illustrato sinteticamente nel documento

2 Dataset

- origine dei dati: da dove proviene il dataset
- dimensione e struttura: numero di righe (osservazioni) e numero di colonne (variabili/feature)
- descrizione delle variabili: tabella o lista con i nomi delle variabili principali, il loro tipo (numerica, categoriale, booleana) e il loro significato
- analisi esplorativa iniziale
 - dati mancanti
 - distribuzione delle variabili chiave
 - valori anomali (outlier)

Il dataset proviene da una banca, la quale ha fornito informazioni riguardo i titolari di carte di credito per prevedere se il cliente è titolare della carta, pagherà o meno il suo prossimo accredito. Per poter condurre tale previsione, il dataset contiene informazioni sulle caratteristiche dei clienti quali ad esempio, genere e età, ma anche il limite di credito, lo storico dei pagamenti e i comportamenti assunti in precedenza.

Il dataset ha 30.000 osservazioni; quindi, si riferisce a ben 30.000 individui e ha 24 variabili. Rispettivamente le variabili contengono:

- 1. LIMIT BAL = è l'importo del credito concesso (in dollari) e include sia il credito al consumo individuale sia quello familiare (supplementare)
- 2. SEX (genere) = che assume valore pari a 1 per i maschi e 2 per le femmine
- 3. EDUCATION (istruzione) 1 = specialistica/master/dottorato, 2 = università, 3 = scuola superiore e 4 = altro
- MARRIAGE 1= sposato/a, 2= single e 3= altro
- ETA' in anni
- PAY0 è lo stato del rimborso a settembre fino a PAY6 che è lo stato del rimborso ad aprile, la scala di misurazione dello stato del rimborso è: -1 pagamento regolare, 1 in ritardo di un mese, fino a 9 in ritardo di 9 o più mesi
- BILLAMT1 è l'importo dell'estratto conto a settembre, fino a BILLAMT6 è l'importo dell'estreatto conto ad aprile
- PAYAMT1 è l'importo del pagamento precedente, in questo caso l'importo pagato a settembre fino a PAYAMT6 che è l'importo pagato ad aprile
- default payment è 1 se ha fatto default e 0 se ha pagato

3 Metodologia

Spiega le tecniche e i passaggi adottati per elaborare e analizzare i dati

- Data cleaning e processing: come ho gestito i dati mancanti, gli outlier, la normalizzazione/standardizzazione o il bilanciamento delle classi
- feature engineering: creazione di nuove variabili a partire da quelle esistenti o trasformazione di variabili categoriali
- modelli/metodi utilizzati: algoritmi scelti (es. regressione logistica, random forest, k-means) e perchè li ho scelti
- validazione: come ho diviso il dataset in Train e Test

4 Risultati

Presenta i risultati oggettivi dell'analisi senza ancora interpretarli profondamente

- metriche di valutazione: mostra la performance dei modelli usando metriche adeguate (es. accuracy, precision, recall, F1-score, RMSE, R^2)
- confronto tra modelli: se hai provato più algoritmi, inserisci una tabella comparativa per mostrare la performance
- visualizzazioni: matrici di confusione, curve ROC, grafici di importanza delle feature o grafici dei cluster

5 Discussione

Interpreta i risultati e ne analizza il significato pratico e i limiti

- interpretazione: cosa significano concretamente i risultati ottenuti rispetto alla domanda iniziale? quali variabili influiscono di più sulle predizioni?
- limiti del lavoro: il dataset era sbilanciato? mancavano informazioni utili? il modello soffre di overfitting?
- punti di forza e debolezze: cosa ha funzionato bene e cosa si sarebbe potuto fare meglio?

6 Conclusione

sintetizzare i punti chiave

- sintesi del lavoro: un breve riassunto di 2-3 frasi sul problema e la soluzione trovata
- takeaway principale: la risposta finale alla domanda di partenza
- sviluppi futuri: cosa si potrebbe fare in seguito per migliorare il progetto (es. raccogliere più dati, provare algoritmi più complessi come reti neurali, etc.)