

Relazione finale progetto

Caterina Ghiani

September 2026

Contents

1	Introduzione	1
2	Dataset	1
2.1	Descrizione delle variabili	1
3	Metodologia	2
4	Risultati	4
4.1	Risultati dell'analisi esplorativa	4
4.1.1	Analisi univariata	4
4.1.2	Analisi bivariata	5
4.2	Tecniche predittive	8
5	Discussione	10
6	Conclusione	11

1 Introduzione

Domanda di ricerca – È possibile prevedere se un cliente andrà in default sul pagamento del mese successivo ($Y = 1$) analizzando il suo profilo demografico, il limite di credito concesso, lo storico dei pagamenti e l'ammontare degli estratti conto passati?

Per le banche, la valutazione del rischio di credito dei propri clienti è fondamentale: essa consente di identificare in anticipo i clienti a rischio di insolvenza, riducendo di conseguenza le perdite. Individuare pattern di comportamento ricorrenti permette inoltre di delineare il profilo dei soggetti potenzialmente meno affidabili.

Il report offre una panoramica sintetica dell'intero processo di analisi condotto, articolato in quattro fasi. La prima fase consiste in un'analisi esplorativa del campione fornito dalla banca, condotta attraverso un'indagine univariata e bivariata volta a delineare il profilo demografico e finanziario dei soggetti. L'obiettivo è comprendere la distribuzione della variabile target Y e le sue relazioni con le altre variabili, formulando e verificando ipotesi utili a individuare i fattori con maggiore potere discriminante.

Nella seconda fase viene descritto il processo di pulizia del dataset: la gestione delle anomalie categoriali, il trattamento del forte sbilanciamento delle classi della variabile target e la creazione di nuovi indicatori sintetici, come il tasso di utilizzo del credito espresso in percentuale, volti ad arricchire la capacità predittiva dei modelli. Dopo aver analizzato il campione e averne corretto le criticità, si procede con la terza fase, ovvero la modellazione predittiva: vengono addestrati tre modelli di classificazione binaria (regressione logistica, k-NN e random forest). Il report si conclude con la quarta fase, un confronto rigoroso delle metriche di performance dei modelli, volto a identificare la soluzione ottimale a supporto delle decisioni di gestione del rischio.

2 Dataset

Il dataset proviene da una banca, la quale ha fornito informazioni riguardo i titolari di carte di credito per prevedere se il cliente è titolare della carta, pagherà o meno il suo prossimo accredito. Per poter condurre tale previsione, il dataset contiene informazioni sulle caratteristiche anagrafiche dei clienti quali ad esempio, genere e età, ma anche il limite di credito, lo storico dei pagamenti e i comportamenti assunti in precedenza.

2.1 Descrizione delle variabili

Il dataset ha 30.000 osservazioni: si riferisce a ben 30.000 individui e ha 24 variabili. Non sono stati trovati dati mancanti. Rispettivamente le variabili contengono:

- **LIMIT_BAL** (numerica discreta) – è l'importo del credito concesso (in

dollari) e include sia il credito al consumo individuale sia quello familiare (supplementare)

- **SEX** (booleana) – il genere del titolare, che assume valore pari a 1 per i maschi e 2 per le femmine
- **EDUCATION** (categoriale ordinale) – l’istruzione del titolare: 1 = specialistica/master/dottorato, 2 = università, 3 = scuola superiore e 4 = altro
- **MARRIAGE** (categoriale nominale) – lo stato civile del titolare: 1 = sposato/a, 2 = single e 3 = altro
- **AGE** (numerica discreta) – l’età del titolare espressa in anni
- **PAY_X** (categoriale ordinale) – è lo stato del rimborso a settembre (**PAY_0**) fino a **PAY_6**, che è lo stato del rimborso ad aprile; la scala di misurazione dello stato del rimborso è: -1 pagamento regolare, 1 in ritardo di un mese, fino a 9 in ritardo di nove o più mesi
- **BILL_AMT** (numerica discreta) – è l’importo dell’estratto conto a settembre (**BILL_AMT1**), fino a **BILL_AMT6**, che è l’importo dell’estratto conto ad aprile
- **PAY_AMT** (numerica discreta) – è l’importo del pagamento precedente, in questo caso l’importo pagato a settembre (**PAY_AMT1**), fino a **PAY_AMT6**, che è l’importo pagato ad aprile
- **default payment** (booleana, variabile target) – è pari a 1 se il titolare ha fatto default e 0 se ha pagato

3 Metodologia

Spiega le tecniche e i passaggi adottati per elaborare e analizzare i dati

- **Data cleaning e processing:**
 - **Gestione nomi colonne:** corretto il nome delle variabili di pagamento (**PAY_X**), rinominando **PAY_0** in **PAY_1** per garantire la sequenzialità temporale con i mesi successivi.
 - **Ricodifica Variabili di Pagamento:** le variabili **PAY_X** presentavano valori da -2 a 8. I valori non morosi (-2: conto inattivo, -1: saldo saldato) sono stati accorpati nella classe unica 0 (“Nessun ritardo”), riservando i valori interi positivi (1, 2, ...) ai mesi effettivi di ritardo nei pagamenti.
 - **Gestione Assenza Dati e Outlier:** in assenza di valori nulli (30.000 osservazioni complete), si è deciso di mantenere gli outlier finanziari per preservare i casi estremi di rischio effettivo.

- **Standardizzazione:** applicato *StandardScaler* su tutte le variabili numeriche continue per azzerare la media e rendere la varianza unitaria, operazione fondamentale per algoritmi sensibili alle distanze (k-NN) e basati su gradiente (regressione logistica).
- **Feature Engineering:**
 - **Credit Utilization Ratio:** crea la variabile sintetica $UTILIZATION_RATIO = (BILL_AMT1 / LIMIT_BAL) \times 100$ per misurare la percentuale di saturazione del tetto di spesa ed eliminare la distorsione di scala dei debiti assoluti.
 - **One-Hot Encoding:** converte le variabili categoriali politomiche (*EDUCATION* e *MARRIAGE*) in variabili dummy binarie per evitare che i modelli lineari o metrici interpretino le categorie come scale ordinali umane.
- **Modelli Utilizzati:**
 - **Regressione Logistica:** scelta come modello parametrico e lineare di *baseline*, ideale per valutare l'interpretabilità dei coefficienti e la separabilità lineare delle classi.
 - **k-Nearest Neighbors (k-NN):** modello non parametrico basato sulla distanza euclidea nello spazio delle features, utilizzato per catturare relazioni di prossimità locale tra i profili dei clienti.
 - **Random Forest:** algoritmo *ensemble* non lineare basato su alberi di decisione, selezionato per la sua capacità di gestire le interazioni complesse tra variabili, l'andamento non-lineare delle feature e per la robustezza all'overfitting.
- **Validazione e Partitioning:**
 - **Train/Test Split:** il dataset è stato suddiviso in un set di addestramento (80%, 24.000 osservazioni) e un set di verifica (20%, 6.000 osservazioni).
 - **Stratificazione:** impostata la stratificazione rispetto al target ($stratify=y$) per mantenere inalterata la proporzione sbilanciata del tasso di default ($\approx 22.1\%$) sia in Train che in Test.
 - **Prevenzione Data Leakage:** La standardizzazione tramite *StandardScaler* è stata fissata unicamente sul set di Train e successivamente applicata al set di Test.

4 Risultati

4.1 Risultati dell'analisi esplorativa

4.1.1 Analisi univariata

1. **Distribuzione della variabile target Y** , i $3/4$ dei soggetti osservati è solvibile, mentre $1/4$ è in default. Questo indica che il nostro dataset non è bilanciato rispetto alla variabile target

	Conteggio (N)	Percentuale (%)
Solvibile (0)	23364	77.88
Default (1)	6636	22.12

Table 1: distribuzione della variabile target Y

2. **Caratteristiche anagrafiche dei nostri soggetti**: il 60% del nostro campione è composto da soggetti di genere femminile. Circa la metà delle persone ha ricevuto un'educazione universitaria e il 35% del campione ha continuato gli studi dopo l'università. Inoltre, rispetto alla situazione sentimentale, ci troviamo davanti ad un campione in cui poco più della metà dei soggetti è single e l'altra metà è sposata (l'1% non ha voluto dichiararlo o non si identifica in nessuna delle categorie).
3. **Età del nostro campione**: il dataset comprende soggetti dai 21 ai 79 anni, ma $3/4$ dei soggetti hanno meno di 41 anni, implicando che i soggetti in età più adulta o anziani non sono granché rappresentati nel nostro campione di popolazione. La media è di 35 anni, questo vuol dire che probabilmente il valore 79 rappresenta un outlier.
4. **Distribuzione del limite di credito accordato**: la media del credito è di 167.484,32 dollari, con una forte deviazione standard. La mediana è inferiore alla media, evidenziando una distribuzione asimmetrica a destra. Difatti, pochi clienti hanno crediti molto elevati e lo possiamo notare anche dal massimo del credito concesso, che è pari a 1 milione.
5. **Analisi dello storico dei pagamenti**: calcolando la distribuzione percentuale dei mesi di ritardo ricostruendo lo storico dei pagamenti, individuiamo che circa l'80% dei soggetti è in pari con i pagamenti della propria carta di credito, con un picco del 90% nel mese di aprile. Si nota anche che i soggetti in ritardo sono solitamente in ritardo di 2 mesi nei pagamenti da effettuare.
6. **Importo delle bollette mensili**: la media dell'importo delle bollette aumenta man mano che si progredisce nell'anno e in tutti i mesi la media è più del doppio della mediana. Il 50% dei clienti ha bollette contenute e approssimativamente degli stessi importi, mentre pochi clienti accumulano

saldi estremamente elevati. I valori negativi non indicano un errore ma implicano un credito a favore del cliente.

4.1.2 Analisi bivariata

1. **L'età differisce in modo significativo tra clienti in default e clienti solvibili?**

Si rileva una mediana pari a circa 34 anni, con un range interquartile compreso tra 28 e 41 anni. La presenza di valori anomali statistici sopra i 60 anni rispecchia quanto visto nell'analisi univariata in cui pochi soggetti hanno un'età avanzata ma non costituiscono un errore, piuttosto rappresentano una situazione realistica. Nel rapporto con la variabile target si evidenzia una quasi totale sovrapposizione tra la distribuzione dei clienti solvibili $Y = 0$ e quelli in default $Y = 1$. Ciò suggerisce che l'età, non è un fattore che determina la capacità di ripagare i propri debiti.




Figure 1: Distribuzione dell'età rispetto alla variabile target Y

2. **Un elevato tasso d'istruzione si associa ad una minore probabilità di default?**

Al diminuire del grado del titolo di studio aumenta il tasso di default: ad un'istruzione più elevata si associa una maggiore probabilità di solvibilità supponendo che sia legata ad un reddito medio più stabile. I clienti

codificati come "Altro" includono anche le anomalie che prima abbiamo ricodificato e registrano un tasso di default estremamente basso (7.1%). Questo potrebbe essere dovuto al fatto che corrispondano a categorie particolari, probabilmente a categorie di soggetti sui quali la stessa banca fa uno screening più approfondito per verificarne l'affidabilità.




Figure 2: Ripartizione percentuale di solvibili e insolventi per titolo di studio

3. Esiste una differenza in base al genere che rende i soggetti più o meno probabili di essere in default?

Calcolando il tasso medio di default per genere possiamo confrontare le percentuali normalizzate: le donne hanno un tasso di insolvenza inferiore rispetto agli uomini (20.85% donne e 24.17% uomini) quindi le donne sono più affidabili degli uomini. A causa della sproporzione nel portafoglio clienti (le donne sono il 60%), in valori assoluti le donne superano gli uomini nei casi di default.

Genere	Solvibili (N)	Solvibili (%)	Default (N)	Default (%)
Maschio (0)	9015	75.83	2873	24.17
Femmina (1)	14349	79.22	3763	20.78

Table 2: Distribuzione del default per genere (valori assoluti e percentuali)

4. Un soggetto sposato è più probabile che sia solvibile?

le categorie "sposato/a" e "single" sono approssimativamente bilanciate

avendo rispettivamente 13.659 e 15.964 soggetti osservati. Questo bilanciamento lo notiamo anche nella distribuzione delle due categorie rispetto alla variabile target. Possiamo dire che tra la variabile target e lo stato civile non vi è una forte correlazione

5. **Un limite di credito concesso più basso segnala un soggetto più a rischio di default?**

Dopo aver diviso in intervalli la variabile, trasformandola da numerica a categorica, ne abbiamo studiato la distribuzione rispetto alla variabile target.

Il grafico mostra una tendenza decrescente, all'aumentare del credito accordato, la percentuale di clienti in default si riduce in modo costante.

- *Fascia ad alto rischio (< 50k)* in cui i clienti hanno un tasso di default più alto di tutti: quasi 1 cliente su 3 in questa fascia va in default;
- *Fascia intermedia (50k - 300k)* il rischio di default diminuisce progressivamente dal 25.8% al 16.1%;
- *Fascia a basso rischio (> 300k)* questi clienti a cui la banca dà molta fiducia, effettivamente hanno una percentuale di default, di 2.4 volte più affidabili della prima fascia.




Figure 3: Tasso di default per fascia di limite di credito

6. **Un elevato rapporto tra spesa mensile e prestito concesso, aumenta la probabilità di default?** (chi usa sempre al massimo il credito concesso, alla fine va in default più spesso di chi invece non raggiunge il

tetto di spesa?)

Dal rapporto dell'ultimo estratto conto (BILL_ATM1) e il limite di credito (LIMIT_BAL) guardiamo il debito in rapporto alla capacità di ripagarlo. Questo indice mostra chi gestisce il credito in modo prudentiale e chi, invece, vive al limite delle proprie disponibilità accordate. Questi ultimi sono i soggetti finanziariamente più vulnerabili: lavorando costantemente a ridosso del tetto massimo di spesa, non dispongono di alcun cuscinetto di liquidità residua. Di conseguenza, di fronte a un piccolo imprevisto o a un'emergenza, la loro probabilità di andare in default aumenta notevolmente.




Figure 4: Tasso di default per fascia di limite di utilizzo del credito

In questo grafico osserviamo:

- Da 1% a 30% è la fascia più stabile, perché è numerosa e con il tasso di default più basso in assoluto
- dal 71% in su invece abbiamo un tasso di default più importante, per cui circa 9 mila soggetti sono ad alto rischio e vivono una situazione di stress finanziario
- anche coloro che sono inattivi, sono però un grande rischio perché sono clienti dormienti.

4.2 Tecniche predittive

Presenta i risultati oggettivi dell'analisi senza ancora interpretarli profondamente

- metriche di valutazione: mostra la performance dei modelli usando metriche adeguate (es. accuracy, precision, recall, F1-score, RMSE, R^2)
- confronto tra modelli: se hai provato più algoritmi, inserisci una tabella comparativa per mostrare la performance
- visualizzazioni: matrici di confusione, curve ROC, grafici di importanza delle feature o grafici dei cluster

5 Discussione

Interpreta i risultati e ne analizza il significato pratico e i limiti

- interpretazione: cosa significano concretamente i risultati ottenuti rispetto alla domanda iniziale? quali variabili influiscono di più sulle predizioni?
- limiti del lavoro: il dataset era sbilanciato? mancavano informazioni utili? il modello soffre di overfitting?
- punti di forza e debolezze: cosa ha funzionato bene e cosa si sarebbe potuto fare meglio?

6 Conclusione

sintetizzare i punti chiave

- sintesi del lavoro: un breve riassunto di 2-3 frasi sul problema e la soluzione trovata
- takeaway principale: la risposta finale alla domanda di partenza
- sviluppi futuri: cosa si potrebbe fare in seguito per migliorare il progetto (es. raccogliere più dati, provare algoritmi più complessi come reti neurali, etc.)